

Comparação de Modelos Supervisionados na Classificação Automática de Modulações com o RadioML 2018.01A

Cleyslon Junio Pereira dos Santos^{*}, Alexandre da Silva Simões[†]

^{*} Universidade Estadual Paulista "Júlio de Mesquita Filho" (UNESP)
Programa de Pós-Graduação em Engenharia Elétrica Interunidades
Faculdade de Engenharia de São João da Boa Vista (FESJ)
São João da Boa Vista, SP, Brasil

[†] Universidade Estadual Paulista "Júlio de Mesquita Filho" (UNESP)
Programa de Pós-Graduação em Engenharia Elétrica Interunidades
Instituto de Ciência e Tecnologia de Sorocaba (ICTS)
Sorocaba, SP, Brasil

Email: ^{*} cleyslon.junio@unesp.br, [†] alexandre.simoes@unesp.br

Resumo—A Classificação Automática de Modulações (*Automatic Modulation Classification*, AMC) é uma tarefa central em sistemas de Rádio e Comunicações Sem Fio, permitindo identificar automaticamente o esquema de modulação de um sinal recebido sem conhecimento prévio do transmissor. Este trabalho compara três modelos de aprendizado supervisionado, *K-Nearest Neighbors* (KNN), *Multi-Layer Perceptron* (MLP) e uma Rede Neural Convolucional unidimensional (CNN 1D), utilizando o conjunto de dados RadioML 2018.01A. Para garantir uma comparação justa, todos os modelos foram avaliados sobre a mesma amostra estratificada do conjunto de dados, diferindo apenas na representação de entrada e na arquitetura empregada. No conjunto de teste, a CNN alcançou acurácia de 55,32%, superando significativamente o KNN (20,12%) e o MLP (19,45%), além de apresentar os melhores valores de F1-score e MCC. A análise por SNR, por família de modulação e por projeções t-SNE indica que a CNN aprende representações mais discriminativas e robustas às variações presentes no RadioML 2018.01A, evidenciando a superioridade de arquiteturas convolucionais para a classificação automática de modulações.

Keywords—Classificação Automática de Modulações, RadioML, Aprendizado Supervisionado, Redes Neurais Convolucionais, Redes Neurais Profundas.

I. INTRODUÇÃO

A crescente demanda por uso eficiente do espectro eletromagnético e o avanço de paradigmas como Rádio Definido por Software (*Software-Defined Radio*, SDR) e Rádio Cognitivo tornaram a Classificação Automática de Modulações (AMC) uma etapa fundamental em receptores inteligentes [1]. A AMC consiste em identificar o esquema de modulação de um sinal recebido sem informação *a priori* sobre o transmissor, viabilizando aplicações como monitoramento de

espectro, detecção de interferência, comunicações militares e coexistência dinâmica de sistemas sem fio.

Abordagens clássicas de AMC dependem de características extraídas manualmente do sinal: estatísticas de ordem superior, momentos cicloestacionários ou transformadas tempo-frequência, combinadas a classificadores estatísticos. Embora eficazes em cenários controlados, essas abordagens exigem forte conhecimento de domínio e tendem a degradar-se em condições realistas de canal, com ruído, deslocamentos de fase e de tempo de símbolo. O advento do aprendizado profundo permitiu que modelos aprendam representações diretamente da forma de onda *I/Q* bruta, dispensando a engenharia manual de atributos e demonstrando ganhos expressivos de desempenho [1], [2].

Neste trabalho, desenvolvido como projeto final da disciplina PGE00029 – *Supervised Machine Learning*, é conduzida uma comparação sistemática entre três paradigmas de aprendizado supervisionado aplicados à AMC sobre o conjunto de dados RadioML 2018.01A [1]: um classificador não-paramétrico baseado em distância (KNN), uma rede neural densamente conectada sem viés indutivo estrutural (MLP) e uma Rede Neural Convolucional unidimensional (CNN 1D), que explora explicitamente a estrutura temporal do sinal. O objetivo central não é apenas reportar métricas de desempenho, mas investigar *por que* arquiteturas com viés indutivo convolucional superam modelos que tratam o sinal como um vetor de atributos independentes, em particular sob o efeito de rotações de fase e deslocamentos temporais aleatórios presentes no RadioML 2018.01A.

As contribuições deste trabalho são: (1) um pipeline reprodutível e computacionalmente eficiente para leitura seletiva do RadioML 2018.01A ($\approx 21,45$ GB), com amostragem

estratificada por (classe, SNR) que preserva o balanceamento original do conjunto de dados; (2) uma metodologia de comparação justa entre modelos com diferentes vieses indutivos, garantindo que KNN, MLP e CNN recebam exatamente a mesma informação de entrada, diferindo apenas na representação estrutural; (3) uma análise quantitativa do desempenho em função da SNR e da família de modulação, evidenciando o papel da invariância a deslocamentos temporais na robustez da CNN às famílias PSK/QAM; e (4) uma discussão fundamentada, apoiada em projeções t-SNE [3], sobre a separabilidade do espaço de *features* bruto *versus* aprendido.

O restante deste artigo está organizado da seguinte forma: a Seção II apresenta a fundamentação teórica das técnicas empregadas; a Seção III descreve o conjunto de dados e o pipeline experimental; a Seção IV apresenta e discute os resultados; e a Seção V conclui o trabalho e aponta direções futuras.

II. FUNDAMENTAÇÃO TEÓRICA

A. O Problema de Classificação Automática de Modulações

Um sinal digitalmente modulado, após demodulação em banda base, é representado por suas componentes em fase e quadratura (I/Q), $x[n] = I[n] + jQ[n]$, $n = 1, \dots, N$. A relação sinal-ruído (SNR), definida como $\text{SNR} = 10 \log_{10} \frac{P_s}{P_n}$, onde P_s e P_n são as potências do sinal e do ruído, respectivamente, determina o grau de degradação da forma de onda observada. No RadioML 2018.01A, cada exemplo é ainda submetido a deslocamentos aleatórios de fase de portadora ϕ_0 e de tempo de símbolo, de modo que a representação observada é

$$r[n] = e^{j\phi_0} s[n - \tau] + w[n], \quad (1)$$

com $s[n]$ o sinal ideal e $w[n]$ ruído aditivo branco gaussiano. Essa rotação de fase aleatória é central para o presente trabalho: qualquer classificador que compare amostras diretamente no domínio I/Q bruto (como a distância euclidiana do KNN) é sensível a ela, pois duas realizações da mesma classe podem estar arbitrariamente distantes nesse espaço.

B. K-Nearest Neighbors (KNN)

O KNN é um classificador não-paramétrico e *lazy*: a etapa de treino consiste apenas em armazenar o conjunto de referência $\{(\mathbf{x}_i, y_i)\}_{i=1}^M$; a inferência atribui a uma amostra $\mathbf{x}$ a classe majoritária entre seus k vizinhos mais próximos segundo uma métrica de distância,

$$\hat{y} = \arg \max_c \sum_{i \in \mathcal{N}_k(\mathbf{x})} \mathbb{I}[y_i = c], \quad (2)$$

onde $\mathcal{N}_k(\mathbf{x})$ é o conjunto dos k vizinhos de $\mathbf{x}$ segundo a distância euclidiana. Por não impor nenhuma estrutura sobre a relação entre atributos, o KNN é um *baseline* adequado para avaliar se a separabilidade das classes já existe no espaço de entrada bruto, sem qualquer aprendizado de representação.

C. Multi-Layer Perceptron (MLP)

O MLP é uma rede neural *feedforward* totalmente conectada, na qual cada camada aplica uma transformação afim seguida de uma não-linearidade,

$$\mathbf{h}^{(l)} = \sigma(\mathbf{W}^{(l)} \mathbf{h}^{(l-1)} + \mathbf{b}^{(l)}), \quad (3)$$

com $\sigma(\cdot)$ tipicamente a função ReLU, $\sigma(z) = \max(0, z)$. Diferentemente do KNN, o MLP aprende uma representação intermediária dos dados, mas cada peso $W_{ij}^{(l)}$ está associado a uma posição fixa do vetor de entrada; não há nenhum mecanismo de compartilhamento de parâmetros ou de invariância a deslocamentos, de modo que um mesmo padrão temporal deslocado no vetor de entrada é tratado como um padrão distinto pela rede.

D. Rede Neural Convolutacional 1D (CNN)

Uma camada convolutacional 1D aplica um mesmo banco de filtros $\mathbf{w}_k \in \mathbb{R}^K$ ao longo de toda a extensão temporal do sinal,

$$z_k[n] = \sigma \left(\sum_{c=1}^2 \sum_{m=0}^{K-1} w_{k,c}[m] x_c[n-m] + b_k \right) \quad (4)$$

o que confere à rede duas propriedades ausentes no MLP: (i) **compartilhamento de parâmetros**, reduzindo drasticamente o número de pesos treináveis; e (ii) **equivariância à translação**, de modo que um padrão detectado por um filtro é reconhecido independentemente de sua posição no sinal. A operação subsequente de *max-pooling*, $y[n] = \max_{m \in [0, P)} z[nP + m]$, introduz tolerância a pequenos deslocamentos, convertendo a equivariância em **invariância local aproximada**. Essa combinação de convolução e *max-pooling* favorece o aprendizado de representações locais mais robustas a pequenas variações temporais e, empiricamente, às variações de fase presentes no RadioML 2018.01A, hipótese central deste trabalho e discutida na Seção IV. Normalização em lote (*Batch Normalization*) [4] é empregada após cada convolução para estabilizar e acelerar o treinamento, e *dropout* [5] regulariza a cabeça de classificação. Arquiteturas convolucionais aplicadas a sinais I/Q brutos têm se mostrado consistentemente superiores a abordagens baseadas em atributos manuais ou em classificadores rasos para AMC [1], [2], [6], e trabalhos recentes exploram tanto arquiteturas mais compactas para embarcados [6] quanto o pré-processamento do sinal para lidar com degradações de canal [7].

III. MATERIAIS E MÉTODOS

A Figura 1 apresenta uma visão geral do *pipeline* experimental, cujas etapas são detalhadas nas subseções a seguir.




Figura 1. Visão geral do *pipeline* da metodologia proposta, da leitura do RadioML 2018.01A à avaliação comparativa dos modelos.

A. Conjunto de Dados

Foi utilizado o RadioML 2018.01A (DeepSig) [1], contendo 2.555.904 sinais sintéticos distribuídos uniformemente entre 24 classes de modulação (OOK, 4/8ASK; BPSK a 32PSK; 16APSK a 128APSK; 16QAM a 256QAM; AM-SSB/DSB com e sem portadora; FM; GMSK; OQPSK) e 26 níveis de SNR (-20 a $+30$ dB, passo de 2 dB), com 4.096 exemplos por combinação (classe (modulações), SNR). Cada exemplo é um vetor I/Q de 1024 amostras complexas. Devido a uma inconsistência documentada no arquivo de mapeamento de classes original do RadioML, foi utilizado o mapeamento corrigido `classes-fixed.json`, evitando associação incorreta entre índice e rótulo de modulação.

B. Amostragem, Divisão e Pré-processamento

Dado o volume do conjunto completo ($\approx 21,45$ GB), foi realizada leitura seletiva do arquivo HDF5: os arrays de rótulo e SNR (pequenos) foram carregados integralmente para guiar a amostragem, enquanto o array de sinais I/Q foi lido apenas nos índices selecionados. Foi extraída uma amostra estratificada por (classe, SNR) de 600 exemplos por célula, totalizando 374.400 exemplos ($\approx 14,6\%$ do conjunto original), preservando o balanceamento perfeito do RadioML. A amostra foi dividida em treino/validação/teste (70%/15%/15%), com estratificação simultânea por classe e SNR, garantindo que cada partição preserve a distribuição original em ambas as dimensões (desvio-padrão das proporções por classe = 0,00000 em todas as partições).

Duas normalizações distintas foram aplicadas, cada uma tecnicamente adequada à representação de entrada correspondente:

- **Z-score** (KNN, MLP): o `StandardScaler` foi ajustado exclusivamente no conjunto de treino e aplicado via *transform* em validação e teste, prevenindo vazamento de dados;
- **Normalização por energia RMS** (CNN): cada sinal é dividido por sua própria energia RMS,

$$\tilde{x}[n] = \frac{x[n]}{\sqrt{\frac{1}{N} \sum_{m=0}^{N-1} |x[m]|^2}}$$

,equivalente a normalizar o ganho do receptor; transformação determinística por amostra, sem risco de vazamento entre partições.

Um único ponto metodológico é central para a validade da comparação: KNN e MLP recebem o sinal achatado em um vetor de 2048 atributos (1024 amostras $\times 2$ componentes), enquanto a CNN recebe a mesma informação em sua estrutura bidimensional original (2×1024). Nenhum modelo tem acesso a mais informação que os demais: a única diferença é a representação estrutural dos dados de entrada, isolando o efeito do viés indutivo arquitetural.

C. Configuração dos Modelos

KNN: `algorithm='brute'` (mais eficiente que estruturas de particionamento espacial em 2048 dimensões), distância euclidiana. Os $k_{\max} = 15$ vizinhos de cada amostra de validação foram calculados uma única vez; o voto majoritário foi então simulado para $k \in \{1, 3, 5, 7, 11, 15\}$ a partir dessa mesma busca, evitando $6 \times$ chamadas redundantes ao índice de vizinhança. O melhor valor obtido foi $k = 3$ (acurácia de validação = 0,1986).

MLP: arquitetura $2048 \rightarrow 512 \rightarrow 256 \rightarrow 24$, com *Batch Normalization*, ReLU e *Dropout*(0,3) em cada camada oculta, totalizando 1.188.120 parâmetros treináveis.

CNN 1D: quatro blocos {Conv1d + BN + ReLU + Max-Pool} com 64, 64, 128 e 128 filtros e *kernels* de tamanho 7, 5, 3 e 3, respectivamente (kernel maior nas camadas iniciais para capturar a forma do pulso; menor nas profundas para compor invariâncias hierárquicas), seguidos de *Global Average Pooling* e uma cabeça densa $128 \rightarrow 64 \rightarrow 24$. Total de 106.072 parâmetros, $11,2 \times$ menos que o MLP.

Ambas as redes foram treinadas com otimizador Adam ($\text{lr} = 10^{-3}$), *loss* de entropia cruzada, tamanho de lote 512 e *early stopping* sobre a perda de validação (paciência de 10 épocas), restaurando os pesos da melhor época. A semente aleatória foi fixada em todos os geradores (Python, NumPy, PyTorch CPU/GPU) para garantir reprodutibilidade. Todo o pipeline foi executado no Google Colab Pro (GPU NVIDIA L4, 23,7 GB).

D. Métricas de Avaliação

Além da acurácia global, foram calculadas métricas macro-balanceadas (Precisão, Recall e F1-score), de modo a não subestimar o desempenho em classes minoritariamente bem-classificadas quando há grande desbalanceamento nos erros. O Coeficiente de Correlação de Matthews (MCC) e o Kappa de Cohen (κ) foram incluídos por serem mais informativos que a acurácia em problemas multiclasse, pois

consideram a matriz de confusão como um todo em vez de apenas sua diagonal. A acurácia também foi decomposta por nível de SNR e por família de modulação, permitindo isolar o efeito do ruído da dificuldade estrutural intrínseca a cada família.

IV. RESULTADOS E DISCUSSÃO

A. Curvas de Treinamento

A Figura 2 mostra as curvas de perda e acurácia do MLP. O modelo converge rapidamente e passa a superajustar já a partir da época 3–4: a perda de treino continua decrescendo monotonicamente até a época 13, enquanto a perda de validação cresce continuamente após seu mínimo, acionando o *early stopping*. Isso indica que a capacidade do MLP (1,19M parâmetros) excede em muito a informação estruturalmente aproveitável no vetor achatado, levando-o a memorizar ruído em vez de aprender um padrão generalizável.




Figura 2. Curvas de perda (entropia cruzada) e acurácia: MLP. Note a divergência entre treino e validação a partir da época 4, caracterizando superajuste.

Em contraste, a Figura 3 mostra que a CNN converge de forma estável por 43 épocas, com perda de treino e validação evoluindo de forma quase paralela até por volta da época 30, configurando um superajuste bem mais brando, apesar de a CNN treinar por 3× mais épocas que o MLP. Isso é um indício direto de que o viés indutivo convolucional atua como um regularizador implícito, permitindo aprendizado generalizável mesmo com 11,2× menos parâmetros que o MLP.




Figura 3. Curvas de perda e acurácia: CNN 1D. Convergência estável, com superajuste leve apenas nas épocas finais.

O KNN, por ser não-paramétrico, não possui curva de treinamento: sua etapa de ajuste é apenas o armazenamento

das 262.080 amostras de treino (0,20 s), com todo o custo computacional deslocado para a inferência (268,4 s no teste, ou 4,78 ms/amostra); comportamento oposto ao das redes neurais, que concentram custo no treino e são baratas na inferência.

B. Comparação Quantitativa entre Modelos

A Tabela I resume o desempenho dos três modelos no conjunto de teste. A CNN supera KNN e MLP em todas as métricas, com ganho de +35,2 pontos percentuais de acurácia sobre o KNN e +35,9 sobre o MLP, apesar de possuir 11,2× menos parâmetros que o segundo. Notavelmente, o MLP obtém desempenho *ligeiramente inferior* ao KNN em quase todas as métricas, apesar de ser uma rede neural com mais de 1,1M de parâmetros, evidência direta de que capacidade bruta do modelo, isolada de vies indutivo estrutural adequado, não se traduz em desempenho no domínio AMC.

Tabela I
COMPARAÇÃO DE DESEMPENHO NO CONJUNTO DE TESTE.

	KNN	MLP	CNN 1D
Accuracy	0,2012	0,1945	0,5532
Precisão (macro)	0,2307	0,1976	0,6143
Recall (macro)	0,2012	0,1945	0,5532
F1-score (macro)	0,1945	0,1698	0,5640
MCC	0,1736	0,1705	0,5359
Cohen's κ	0,1664	0,1595	0,5338
Tempo de treino	0,20 s	46,65 s	1008,96 s
Parâmetros / custo	262.080 amostras	1.188.120	106.072

A Figura 4 ilustra visualmente essa distância consistente entre a CNN e os dois *baselines* em todas as métricas: o padrão se repete de forma quase idêntica em Accuracy, F1, MCC e κ , reforçando que o ganho não é um artefato de uma métrica específica, mas uma melhoria estrutural de classificação.




Figura 4. Comparação de métricas macro-balanceadas entre os três modelos.

C. Análise por Relação Sinal-Ruído

A Figura 5 mostra a acurácia em função da SNR. Todos os modelos colapsam para próximo do acaso ($1/24 \approx 0,042$)

em $\text{SNR} \leq -14$ dB. A partir de -10 dB, porém, os comportamentos divergem drasticamente: a CNN cresce de forma quase sigmoideal até saturar em $\approx 0,87$ já em torno de 10 dB, enquanto KNN e MLP saturam precocemente em torno de $0,25$ – $0,31$, mesmo em SNR muito alta (30 dB). Esse platô baixo em alta SNR é a evidência mais direta de que a limitação de KNN e MLP não é ruído: é a incapacidade estrutural de lidar com a rotação de fase e o deslocamento temporal aleatórios do RadioML, presentes mesmo em sinais praticamente limpos.




Figura 5. Acurácia em função da SNR para os três modelos.

D. Matrizes de Confusão e Padrões de Erro por Família

A Figura 6 revela um padrão de erro qualitativamente distinto entre os *baselines* e a CNN. O KNN concentra a maioria de suas predições incorretas na classe *AM-DSB-SC* (uma coluna quase inteiramente escura na matriz, presente inclusive para classes PSK e QAM sem qualquer relação espectral com AM), enquanto o MLP apresenta um viés semelhante concentrado na classe *16PSK*. Esse não é um padrão de erro aleatório, mas um colapso de decisão: diante da alta sobreposição das classes PSK/QAM no espaço bruto *I/Q* rotacionado, ambos os modelos aprendem a prever preferencialmente uma única classe “coringa”. Já a CNN exibe uma diagonal consistentemente dominante em todas as 24 classes, com confusão residual concentrada apenas entre classes estruturalmente próximas: principalmente $64/128/256\text{QAM}$ entre si, e $16\text{PSK}/32\text{PSK}$ entre si.




Figura 6. Matrizes de confusão normalizadas (recall por classe): KNN, MLP e CNN.

A decomposição por família de modulação confirma esse padrão para a CNN: as famílias FM/GMSK/OQPSK e ASK saturam próximo de 100% já a partir de ≈ 0 – 10 dB; PSK e APSK convergem para 90 – 95% ; QAM de alta ordem é a única família que não ultrapassa ≈ 70 – 72% mesmo em 30 dB, e o recall por classe da CNN é consistentemente mais baixo para 128QAM ($0,23$) e 256QAM ($0,29$), as duas constelações mais densamente empacotadas do conjunto, onde a distância mínima entre símbolos vizinhos é pequena mesmo sem ruído algum.

E. Separabilidade do Espaço de Representação

A Figura 7 projeta via t-SNE [3] o espaço bruto *I/Q* (usado por KNN/MLP) e o espaço de *features* de 128 dimensões extraído pela CNN (antes da camada classificadora), restrito a $\text{SNR} \geq 18$ dB para maximizar a separabilidade. No espaço bruto, apenas duas classes (as de maior amplitude/estrutura diferenciada, tipicamente OOK e 4ASK) formam agrupamentos parcialmente isolados; as demais 22 classes se sobrepõem em uma nuvem única e indistinguível. No espaço aprendido pela CNN, praticamente todas as 24 classes formam agrupamentos bem separados, com poucas sobreposições concentradas exatamente entre as famílias QAM/PSK de alta ordem já identificadas como mais difíceis. Essa visualização fornece evidência direta (complementar às métricas quantitativas) de que o ganho de desempenho da CNN decorre do aprendizado de uma representação intermediária mais discriminativa.




Figura 7. Projeções t-SNE: espaço bruto *I/Q* (KNN/MLP) vs. *features* aprendidas pela CNN ($\text{SNR} \geq 18$ dB).

F. Síntese da Discussão

Em conjunto, os quatro tipos de evidência apresentados (matrizes de confusão, curvas de acurácia por SNR, decomposição por família e projeções t-SNE) convergem para uma única explicação causal, e não apenas correlacional: a vantagem da CNN sobre KNN e MLP no RadioML 2018.01A decorre especificamente de sua invariância parcial a deslocamentos de fase e de tempo de símbolo, obtida pelo par *convolução+pooling* (Seção II), e não de sua maior capacidade de representação em termos absolutos, que, de fato, é $11,2\times$ menor que a do MLP em número de parâmetros.

V. CONCLUSÃO

Este trabalho comparou três abordagens de aprendizado supervisionado (KNN, MLP e CNN 1D) para Classificação Automática de Modulações no RadioML 2018.01A, sob uma metodologia que isola rigorosamente o efeito da arquitetura do efeito da informação disponível: todos os modelos recebem exatamente o mesmo conteúdo informacional, diferindo apenas na representação estrutural da entrada. Os resultados mostram que a CNN supera KNN e MLP em todas as métricas avaliadas (acurácia de 0,5532 vs. 0,2012 e 0,1945, respectivamente), apesar de possuir $11,2\times$ menos parâmetros que o MLP, evidência de que, neste domínio, viés indutivo arquitetural adequado é mais determinante para o desempenho do que capacidade bruta de representação.

A hipótese central investigada, de que a vantagem da CNN decorre especificamente de sua invariância parcial a deslocamentos de fase e de tempo de símbolo, foi corroborada por quatro linhas de evidência convergentes: (i) o colapso de decisão do KNN e do MLP em classes "coringa" nas matrizes de confusão; (ii) a saturação precoce e em patamar baixo de KNN/MLP mesmo em SNR alta, onde o ruído deixa de ser o fator limitante; (iii) o padrão de acurácia por família de modulação, com QAM de alta ordem consistentemente mais difícil para todos os modelos; e (iv) a separabilidade visivelmente superior do espaço de *features* aprendido pela CNN frente ao espaço bruto I/Q , evidenciada via t-SNE.

Como limitações, destacam-se: a amostragem de apenas $\approx 14,6\%$ do conjunto original (por restrição computacional, sobretudo do KNN); a ausência de busca extensiva de hiperparâmetros; e o desempenho ainda limitado da CNN nas classes de maior ordem (128QAM, recall = 0,23; 256QAM, recall = 0,29). Como trabalhos futuros, propõe-se: (1) pré-processamento por magnitude/fase diferencial; (2) arquiteturas mais profundas com blocos residuais 1D, seguindo a tendência observada na literatura recente de AMC [2], [6], [7]; e (3) ampliação do conjunto amostrado, condicionada à disponibilidade computacional.

AGRADECIMENTOS

Agradeço ao Prof. Dr. Alexandre da Silva Simões pela orientação e pelo material didático da disciplina PGE00029 – *Supervised Machine Learning*, do Programa de Pós-Graduação em Engenharia Elétrica Interunidades da UNESP, que fundamentou parte da revisão teórica apresentada neste trabalho.

REFERÊNCIAS

- [1] T. J. O'Shea, T. Roy, and T. C. Clancy, "Over-the-air deep learning based radio signal classification," *IEEE Journal of Selected Topics in Signal Processing*, vol. 12, no. 1, pp. 168–179, 2018.
- [2] Y. Wang, M. Liu, J. Yang, and G. Gui, "Data-driven deep learning for automatic modulation recognition in cognitive radios," *IEEE Transactions on Vehicular Technology*, vol. 68, no. 4, pp. 4074–4077, 2019.
- [3] L. van der Maaten and G. Hinton, "Visualizing data using t-sne," *Journal of Machine Learning Research*, vol. 9, pp. 2579–2605, 2008.
- [4] S. Ioffe and C. Szegedy, "Batch normalization: Accelerating deep network training by reducing internal covariate shift," in *Proceedings of the 32nd International Conference on Machine Learning (ICML)*, 2015.
- [5] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A simple way to prevent neural networks from overfitting," *Journal of Machine Learning Research*, vol. 15, no. 1, pp. 1929–1958, 2014.
- [6] J. Rosa, D. Granhão, G. Carvalho, T. Gonçalves, M. Figueiredo, L. C. Bento, N. Paulino, and L. M. Pessoa, "Bacalhaunet: A tiny cnn for lightning-fast modulation classification," *ITU Journal on Future and Evolving Technologies*, vol. 3, no. 2, 2022.
- [7] S. Lee, Y.-I. Yoon, and Y. J. Jung, "Generative adversarial network-based signal inpainting for automatic modulation classification," *IEEE Access*, 2023.